

Eksploracja danych i wyszukiwanie informacji w mediach społecznościowych

Wykład 5 - analiza sentymentu

dr inż. Julian Sienkiewicz

5 listopada 2018

Emocje – ogólny opis

- wg. Wiki: “świadome lub nieświadome silne, względnie nietrwałe, **gwałtowne uczucia** o silnym zabarwieniu i wyraźnym wartościowaniu (o charakterze pobudzenia pozytywnego lub negatywnego), poprzedzone jakimś wydarzeniem i ukierunkowane”,
- emocje mają stricte **naturę społeczną** (co obserwował już Darwin w XIX w.) – oznacza to, że mogą być wywoływane przez innych ludzi oraz działać na innych ludzi w społeczeństwie,
- tym bardziej kluczową kwestią jest w jaki sposób obserwować **emocje w Internecie**, czyli miejscu, gdzie w bardzo łatwo mogą się przenosić lub oddziaływać,
- ze względu na ilość danych, najprościej jest analizować **zbiory tekstowe**, oczywiście emocje obserwowane są również (lub przede wszystkim) w przekazach audio, wideo lub w postaci graficznej

Istnieje szereg różnych sposobów określania poziomu emocji i też szereg modeli, które mają to reprezentować.


Emocje podstawowe

Powszechnie znane są tzw **emo-cje podstawowe**, wprowadzone przez Paula Ekmana – na kanwie tego podejścia powstał znany film animowany *W głowie się nie mieści* (*Inside Out*).



Model kołowy Russela

Istnieje także tzw. **model kołowy Russela**, oparty na dwóch wymiarach: **walencji** (znak emocji: pozytywny, negatywny) oraz **pobudzenie** (nateżenie emocji: niskie, wysokie). Za pomocą kombinacji tych wartości można określić poszczególne emocje.



Analiza sentymentu (*sentiment analysis*) opiera się w pewnym stopniu na rozróżnieniu pomiędzy **faktami** a **opiniami**

Fakty

Fakty to najczęściej **obiektywne** wyrażenia (czyli zwroty), odnoszące się do bytów (np. ludzi), zdarzeń oraz ich własności.

Opinie

Opinie to najczęściej **subiektywne** wyrażenia, opisujące ludzkie emocje, oceny lub odczucia związane z bytami, zdarzeniami oraz ich własnościami.

Metody analizy sentymentu i pokrewnych pojęć mają wiele nazw:

- opinion mining,
- review mining,
- appraisal extraction

emocje

=

opinie

=

subiektywność

Subiektywność

Subiektywność to wyrażenie **lingwistyczne** określające czyjeś opinie, uczucia, emocje, oceny, wierzenia lub przypuszczenia (**stany prywatne**).

Stany prywatne

Stan prywatny to stan, który nie jest dostępny obiektywnej obserwacji ani też weryfikacji (sprawdzeniu).

Przykłady

- "Dobrze się dziś czuje",
- "Jestem bardzo szczęśliwy, że tak się to skończyło",
- "Zupełnie się z Tobą nie zgadzam"

Dwupoziomowa klasyfikacja

W większości przypadków jeśli mamy do oceny dokument, co do którego nie wiemy, czy zawiera on jakiegolwiek wyrażenia dotyczące stanów prywatnych, musimy wykonać dwa zadania:

- identyfikacja **subiektywności** / **obiektywności** czyli klasyfikujemy dokument jako albo subiektywny albo też jako obiektywny
- określenie polarności - **pozytywny** / **negatywny**
czyli sprawdzenie, czy wyrażana opinia jest pozytywna czy negatywna

Przykład

Mając do dyspozycji post z forum nie wiemy a priori, czy zawiera on jakąś opinię, Równie dobrze może po prostu odnosić się do jakiegoś faktu.

Problemy

- bardzo ciężko jest znaleźć konkretne słowa kluczowe, które pozwalają na rozróżnienie polarności,
- badania pokazują, że średnio otrzymujemy w okolicach 60% skuteczności w klasyfikacji opartej na słowach kluczowych

Przykłady

- *If you are reading this because it is your darling fragrance, please wear it at home exclusively and tape the windows shut.* **Brak negatywnych słów.**
- *Miss Austen is not a poetess.* **Fakt czy opinia?**
- *This film should be brilliant. It sounds like a great plot, the actors are first grade, and the supporting cast is good as well, and Stallone is attempting to deliver a good performance. However, it can't hold up.* **Genralnie większość pozytywów...**
- *Yeah, sure!,* **Ironia**
- *If you thought this was going to be a good movie, I am sorry to disappoint you.* **Negacja**

Podjęcie pod nadzorem

- inaczej klasyfikacja metodami machine learning
- określamy ogólne **właściwości matematyczne**, które mają być wzięte pod uwagę,
- określamy również ogólne własności **kryterium decyzyjnego**,
- faktyczna decyzja jest podejmowana na podstawie danych treningowych – stąd podjęcie **pod nadzorem**

Podjęcie bez nadzoru

- np. “jeśli liczba pozytywnych przymiotników jest większa niż liczba negatywnych przymiotników, skasyfikuj dokument jako pozytywny”
- wydaje się proste, ale i tak trzeba zebrać listę słów z określonym sentymentem oraz wykonać POS,
- nie każde podjęcie jest aż tak trywialne

Przewaga podejścia bez nadzoru

- raz zaimplementowane **działa wszędzie** (z różnym skutkiem),
- brak potrzeby stosowania **danych treningowych**,
- możliwe do adaptacji w wielu różnych dziedzinach,
- szybkie,
- bardziej **intuicyjne**,
- łatwo **rozszerzalne** – wystarczy dodać nowy słownik (nowe słowa),

Mankamenty

- generalnie jeden, ale poważny mankament – ma niższą skuteczność niż podejście pod nadzorem

Przykład podejścia bez nadzoru – Turney (2002)

- mając dany dokument wyodrębnij następujące po sobie słowa, które spełniają określone zależności POS:
 - 1 przymiotnik + rzeczownik + dowolne
 - 2 przysłówek + przymiotnik + NIE rzeczownik
 - 3 przymiotnik + przymiotnik + NIE rzeczownik
 - 4 rzeczownik + przymiotnik + NIE rzeczownik
 - 5 przysłówek + czasownik + dowolne
- określ **orientację semantyczną (SO)** wyodrębnionych wyrażeń jako

$$SO(\text{wyrażenie}) = PMI(\text{wyrażenie}, \text{"excellent"}) - PMI(\text{wyrażenie}, \text{"poor"})$$

gdzie

$$PMI(\text{słowo}_1, \text{słowo}_2) = \log_2 \frac{\Pr(\text{słowo}_1 \ \& \ \text{słowo}_2)}{\Pr(\text{słowo}_1) \Pr(\text{słowo}_2)}$$

to tzw. punktowa informacja wzajemna (*pointwise mutual information*).

Turney (2002)

- prawdopodobieństwa estymujemy otrzymując liczbę trafień w wyszukiwaniu (np. Google) – $\text{traf}(N)$ w poniższych wzorach,
- w efekcie mamy:
- określ **orientację semantyczną (SO)** wyodrębnionych wyrazów jako

$$SO(\text{wyrażenie}) = \log_2 \frac{\text{traf}(\text{wyrażenie BLISKO "excellent"})\text{traf}(\text{"poor"})}{\text{traf}(\text{wyrażenie BLISKO "poor"})\text{traf}(\text{"excellent"})}$$

natomiast całkowita wartość SO jest sumą po SO wszystkich zidentyfikowanych wyrazów:

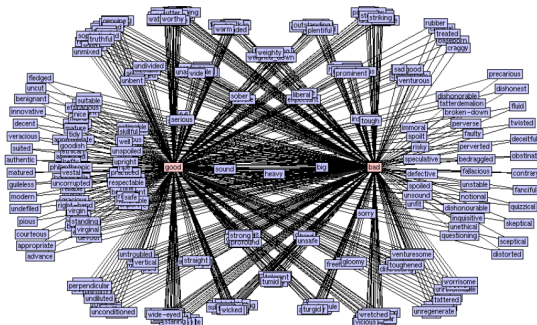
$$SO(\text{dokument}) = \sum_{\text{wyrażenie}} SO(\text{wyrażenie})$$

to tzw. punktowa informacja wzajemna (*pointwise mutual information*).

- finalnie, jeśli $SO > 0$, to dokument lub zdanie jest pozytywne, w przeciwnym przypadku $SO < 0$ – negatywne

Inne podejście – Kamps et al. (2002)

- użycie słownika **WordNet** (SłowoSieć) do automatyczne określenia sentymentu przymiotników,
- węzłami sieci są **słowa** (z POS), linkami **relacje synonimiczne** pomiędzy nimi,
- patrzymy na **najkrótszą drogę** $d(A, B)$ pomiędzy węzłami A i B



Kamps et al. (2002)

Oceniamy orientację semantyczną przymiotnika *w* na trzech poziomach, licząc odległości pomiędzy określonymi uprzednio słowami...

- ewaluacja - dobry / zły: $\frac{d(w, \text{good}) - d(w, \text{bad})}{d(\text{good}, \text{bad})}$,
- potencja - silny / słaby: $\frac{d(w, \text{weak}) - d(w, \text{strong})}{d(\text{weak}, \text{strong})}$,
- aktywność - aktywny / pasywny: $\frac{d(w, \text{passive}) - d(w, \text{active})}{d(\text{passive}, \text{active})}$,

Skuteczności

To i poprzednie podejście uzyskiwały całkiem dobre skuteczności:

- SO - oceny samochodów: 84 %,
- SO - oceny banków: 80 %,
- SO - oceny filmów: 66 %,
- ewaluacja: 68 %,
- potencja: 71 %,
- aktywność: 61 %

Przykład podejścia pod nadzorem – Pan, Lee, Vaithyanathan (2002)

- 3 techniki uczenia maszynowego:
 - 1 naiwny Bayes (NB),
 - 2 zasada maksymalnej entropii (ME),
 - 3 maszyny wektorów nośnych (SVM)
- usunięte tagi HTML, bez stemowania i usuwania słów kluczowych
- **unigramy**, słowa występujące co najmniej 4 razy w tekście,
- **dodanie słowa NOT** do każdego pomiędzy negacją a koncem zdania (np. "The movie was not very good-> "The movie was NOT very NOT good")
- również oddzielnie **bigramy**, bez narzucania negacji,
- dodanie **tagów POS**,
- **rozdzielenie na sekcje** w zależności od położenia w dokumencie: pierwsza ćwiartka, ostatnia ćwiartka, reszta

Pan, Lee, Vaithyanathan (2002)

- różne kombinacje, każda dla 3 metod ML:
 - unigramy,
 - unigramy + TF,
 - unigramy + bigramy
 - bigramy
 - unigramy + połączenie etc
- wartości od 72 do 83%
- najlepsze efekty dla binarnych unigramów i metody SVM– 82.9 %,

Paltoglou i Thalwell (2010)

- użycie **TF-IDF** zamiast binarnych wag czy częstościowych,
- nawet 95 % (klasyfikator SVM),